R05229014 鄒適文 r05229016 羅章碩

1. Model description

字典大小:2712

Cell: 128 個 gru cell(2 層)

Optimizer: Adam, learning rate = 0.001 並隨時間慢慢下降

使用 attention、schedule sampling,另外在 rnn 裡面似乎無法使用 batch 來

train, 所以我在 pytorch 裡面使用了 PackedSequence 來解決這個問題.

Iteration: 10000, batch size = 64

2. How to improve your performance

● Schedule Sampling: teacher forcing 每次都提供正確答案給模式

● 似乎在文本過大(或是字典過大)的情況下,必須每次都給模式正確答案 才會讓模式寫出"稍微"合乎文法的句子,在沒有使用 teacher forcing 的 況下,基本上在我的實驗中句子都會全部爛掉,不是文法不對,就是 只會一直吐出重複的字詞,或是不管怎麼樣的輸入都吐出一樣的字 詞,而那些字詞是機率最大的字詞。

● 使用前 使用後



3. Experimental results and settings

Training 方法: 將助教提供的電影文本,相鄰的兩句當作一對,前句做輸入,後句作為輸出

實驗心得:

一開始我在 train 的時候瘋狂失敗,正考慮要不要停修的時候,使用的 model 跟現在 train 起來的 model 架構幾乎相同的,除了字典大小為 20 萬字,並且將助教提供的整個文本都讀進來 train。

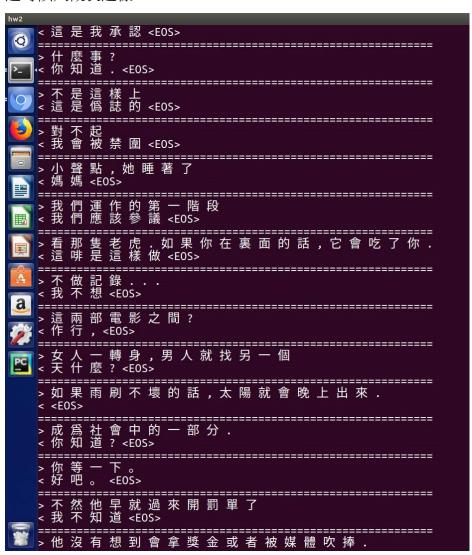
這時候的模式 output 大概長這樣:

```
-3.192
                  我
                      的 <EOS>
               的的
                      <EOS>
-3.240
         <
                   $
                      <EOS>
的 <EOS>
的 ? <EO
 3.260
                  "你我我你我
                         ? <E0S>
                        <EOS>
                      的 ? <EOS>
    494
                        <EOS>
           我我我我我我好了!
               <EOS>
               , <EOS>
-2.769
                  我 <EOS>
               的 <EOS>
 2.974
        <
                  你的
-3.024
                     <EOS>
                      <EOS>
                   <EOS>
                        <EOS>
                  的我你
                     ? <EOS>
的 <EOS>
的 <EOS>
的 ? <EOS>
   256
-3.309
                  你的? <EOS>
我! <EOS>
我的? <EOS>
我, <EOS>
 3.501
-3.504
               <EOS>
         <
                  <E0S>
               的的
                  <EOS>
   046
                      <EOS>
                      的 <EOS>
                       <EOS>
                      的 <EOS>
    146
   146
                      <EOS>
                      <EOS>
                      <EOS>
                      是了的的
                         ? <E0S>
3.440
         <
                          <EOS>
                         ? <E0S>
-3.498 <
-3.499
        <
```

但是 train 了一整個禮拜結果還是非常糟糕的,覺得可能是因為文本、字典數量太大,導致模式的能力不足以學會人類講話的思考方法(考慮到生物學? 腦容量太小是學不會講話的(誤?),因此決定把字典從 20 萬下調(這時候看到助教公布的 language model 字典數量是兩千),我就把我的字典數量下調到差不多兩千,並且 training data 的文本過濾,只把前句為主詞,也就是{你,我,他,你們,我們,他們...}的句子留下,作為 training data,並且同時加上 teacher forcing.

就.......就突然突破 baseline 了...,並且句子看起來蠻像正常的句子。

這時候大概長這樣:



結論:

將 training data 變成比較有意義的 pair 顯然會對模式的學習有很大的幫助,並且調小字典、使用 teacher forcing 讓模式不會重複輸出最常出現的回答,便會使結果變好。